

**ROTEIRO DE AULA PRÁTICA**

# Engenharia de Requisitos para ML com GR4ML

---

*Caderno de Exercícios do Grupo*  
Preencha os templates de cada fase durante a aula

**Centro de Informática — CIn/UFPE**  
Especialização em Deep Learning · Disciplina: Engenharia de Software para IA

| Grupo (nome dos integrantes) | Projeto da disciplina |
|------------------------------|-----------------------|
| <i>Evelin Limeira</i>        | Sentiment Analysis    |
| <i>João Vítor Araújo</i>     | Sentiment Analysis    |
| <i>Jade Colpani</i>          | Sentiment Analysis    |
| <i>Clayton Liberato</i>      | Sentiment Analysis    |
| <i>Raffael Paiva</i>         | Sentiment Analysis    |

# Como usar este caderno

Este material acompanha o roteiro de aula prática de Engenharia de Requisitos com o framework GR4ML (Goal-Oriented Requirements Engineering for Machine Learning). Cada fase da aula está organizada da mesma forma, para facilitar o acompanhamento:

-  **Ideia central** — uma explicação simples do que a fase/ passo quer resolver, sem jargão técnico.
-  **Exemplo** — um exemplo já resolvido, usando o caso de uma plataforma de streaming que quer reduzir cancelamento de assinaturas (nosso 'fio condutor' do início ao fim).
-  **Entregável** — a frase que diz exatamente o que vocês precisam ter em mãos ao final daquele passo.
-  **Espaço para preencher** — um template em branco para o grupo completar com o próprio projeto, durante a aula.
-  **Checkpoint** — um ponto de parada para o professor validar o progresso do grupo antes de seguir adiante.

 **Objetivo da atividade**

Capacitar os alunos a elicitar, modelar e alinhar requisitos de negócio com decisões de design analítico e pipelines de dados utilizando o GR4ML, garantindo que o modelo de Machine Learning atenda a um valor real de negócio — e não apenas a uma métrica técnica isolada.

## Cronograma sugerido

| Fase                                | Duração | Conteúdo                                                                 |
|-------------------------------------|---------|--------------------------------------------------------------------------|
| Fase 0 — Alinhamento                | 20 min  | Escopo do projeto, stakeholder principal e dor de negócio                |
| Fase 1 — Business View              | 45 min  | Atores, objetivos, indicadores, decisões e perguntas de negócio          |
| Fase 2 — Analytics Design View      | 45 min  | Tipo de análise, tarefas de ML, algoritmos, softgoals e métricas         |
| Fase 3 — Data Preparation View      | 45 min  | Fontes de dados, transformações e pipeline até o dataset final           |
| Fase 4 — Dos modelos aos requisitos | 30 min  | Tradução dos modelos em Requisitos Funcionais, Não-Funcionais e de Dados |

## As três visões do GR4ML, em uma tabela

| Visão                    | Pergunta que responde                        | Quem pensaria assim, na vida real | O que sai dela                                             |
|--------------------------|----------------------------------------------|-----------------------------------|------------------------------------------------------------|
| 1. Business View         | Quem precisa de quê, e por quê?              | Gestor / dono do produto          | Diagrama Ator → Goal → Decision Goal → Question Goals      |
| 2. Analytics Design View | Que modelo resolve isso, com qual qualidade? | Cientista de dados                | Tarefas de ML, algoritmos e métricas ligadas aos softgoals |
| 3. Data Preparation View | De onde vêm os dados e como chegam prontos?  | Engenheiro de dados               | Pipeline de dados brutos até features prontas              |



## FASE 0 — Alinhamento de Contexto

20 minutos · antes de abrir qualquer ferramenta de modelagem

Ideia central: antes de pensar em modelo ou algoritmo, o grupo precisa conseguir resumir o projeto em um parágrafo simples. Identifiquem claramente quem é o principal patrocinador (stakeholder) do projeto e qual dor de negócio motivou a criação do sistema de ML.



### Exemplo (streaming)

- "O Gerente de Retenção de Clientes da plataforma quer reduzir o cancelamento de assinaturas, que hoje é decidido caso a caso sem nenhum critério preditivo, causando perda de receita recorrente."



**ENTREGÁVEL DESTE PASSO:** Um parágrafo curto (3–5 linhas) descrevendo o stakeholder principal e a dor de negócio do projeto de vocês. Essa frase será a 'âncora' de todas as fases seguintes.



### Espaço para o grupo preencher

Os gerentes de vendas e CRM querem classificar avaliações (*reviews*) negativas de produtos vendidos que hoje passam por uma triagem manual lenta e ineficiente diante do alto volume de dados. Essa demora no atendimento gera insatisfação e perda de clientes. O sistema de ML automatizará a detecção de sentimento negativo, alertando o time e indicadores em tempo real para permitir um contato imediato e focado na retenção do cliente.

## 1 FASE 1 — Business View (Visão de Negócio)

45 minutos · mapeando intenções estratégicas, sem pensar em algoritmos ainda

Objetivo desta fase: mapear as intenções estratégicas do negócio e como o ML pode apoiar a tomada de decisão humana.

### PASSO 1.1 Identificar o Ator de negócio

Pergunte: quem vai usar essa solução no dia a dia? Essa pessoa representa qual papel na organização?

#### 💡 Exemplos de Atores

- Streaming → Gerente de Retenção de Clientes
- Fraude → Gerente de Prevenção a Fraudes
- Saúde → Médico Oncologista
- Hospital (fluxo de atendimento) → Coordenador de Enfermagem

📌 **ENTREGÁVEL DESTE PASSO:** Uma tabela com 1 linha por ator, contendo nome do ator e papel na organização (2 a 4 atores costuma bastar).

| Nome do Ator                              | Papel na organização                                                                                                                                                                                              |
|-------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Gerente de CRM                            | Responsável pelas estratégias de retenção, fidelização e relacionamento com o cliente.                                                                                                                            |
| Gerente de Vendas                         | Responsável por acompanhar o desempenho e aceitação dos produtos no mercado. É o principal interessado em usar o feedback dos clientes para identificar problemas em produtos e evitar queda no volume de vendas. |
| Atendente do Serviço de Atendimento (SAC) | Operacionaliza o atendimento direto. Será o responsável por receber o alerta de review negativo, analisar o histórico do cliente e realizar os contatos para solução e reversão do cliente.                       |

### PASSO 1.2 Definir o Goal (objetivo) e anotar expectativas de qualidade

Goal: o que esse ator quer alcançar, de forma mensurável. Indicador: a métrica numérica que mostra progresso desse Goal. Além disso, anotem (ainda de forma informal) frases do stakeholder sobre o que ele valoriza além do número principal — isso será formalizado como Softgoal só na Fase 2.

#### 💡 Exemplo (streaming)

- Goal: "Reduzir o cancelamento de assinaturas em 15% este ano"
- Indicador: taxa mensal de churn (%) — atual: 5% · meta: 4,25%
- Anotação informal de qualidade: "O time de retenção mencionou que a lista de clientes em risco precisa estar pronta toda segunda-feira de manhã, sem exceção."

📌 **ENTREGÁVEL DESTE PASSO:** Para cada ator: o Goal, o Indicador (com valor atual e meta, se souberem) e 2–3 frases de qualidade esperada, em linguagem do negócio (ainda sem termos técnicos).

| Ator                                      | Goal (objetivo)                                                                                                                | Indicador (métrica)                                                                                      | Expectativas de qualidade (informal)                                                                                                                                     |
|-------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Gerente de CRM                            | Melhorar a retenção de clientes que tiveram experiências negativas para 35%                                                    | Atual: 15% Meta: 35%                                                                                     | “Precisamos tratar as insatisfações e avaliações negativas para garantir que o cliente continue interessado em adquirir o produto, mesmo após uma experiência negativa.” |
| Gerente de Vendas                         | Manter a taxa de avaliação positiva dos produtos acima de 85% no e-commerce                                                    | Média de estrelas dos produtos:<br>Atual: 3.9<br>Meta: 4.3                                               | “As justificativas das notas ruins precisam ser fáceis de entender para o time de produto.”                                                                              |
| Atendente do Serviço de Atendimento (SAC) | Diminuir o SLA de resposta para menos de 1 dia útil e aumentar a conversão de notas negativas para neutras ou positivas em 10% | SLA atual: 3 dias úteis<br>SLA Meta: Menos que 8 horas<br><br>Conversão atual: 2%<br>Conversão Meta: 10% | “Preciso que o alerta chegue direto na minha fila sem eu ter que ficar lendo milhares de reviews positivos à toa.”                                                       |

### PASSO 1.3 Decision Goal — a decisão que o ator precisa tomar

Uma decisão é sempre uma escolha entre opções — algo que alguém faz repetidamente. Se vocês não conseguem descrever uma escolha concreta, ainda não acharam a decisão certa.

#### Exemplos

- *Streaming*: "Decidir para quais clientes oferecer um desconto de retenção este mês" (opções: desconto A, desconto B, nenhuma ação)
- *Fraude*: "Decidir se uma transação deve ser bloqueada, sinalizada para revisão manual, ou aprovada"
- *Hospital*: "Decidir qual paciente deve ser atendido primeiro na triagem"

#### Cuidado com este erro comum

"Entender os clientes" não é uma decisão — é um desejo vago. Pergunte sempre: decidir entre o quê?

 **ENTREGÁVEL DESTE PASSO:** Uma frase por ator, no formato: '[Ator] precisa decidir [entre quais opções], com que frequência'.

O Atendente de SAC precisa decidir entre realizar um contato telefônico de alta prioridade, enviar um e-mail padronizado com desculpas e uma explicação do ocorrido ou descartar o alerta e sinalizar o motivo (Ironia, falso positivo, outros...) para cada nova review classificada como negativa.

O Gerente de CRM precisa decidir entre incluir o cliente insatisfeito em uma régua especial, focada em retenção de clientes potencialmente insatisfeitos, inserir o cliente em um fluxo de reengajamento ou manter uma comunicação ativa.

O Gerente de Vendas precisa decidir entre autorizar uma oferta comercial exclusiva de recompra para o cliente insatisfeito, oferecer cupons de desconto ou entender, junto com o fornecedor do produto a existência de defeitos ou problemas no produto vendido.

### PASSO 1.4 Question Goals — as perguntas que respondem à decisão

Desdobrem o Decision Goal em uma ou mais perguntas específicas que o modelo de ML precisa responder para apoiar a decisão. Especifiquem também o tipo de pergunta (quem/o quê/quando...), o tempo verbal (passado/presente/futuro) e a frequência necessária da resposta.

### 💡 Exemplos


- *Streaming*: "Quais clientes têm alta chance de cancelar a assinatura nos próximos 30 dias?" → tipo: quem · tempo: futuro · frequência: mensal
- *Fraude*: "Essa transação específica é fraudulenta?" → tipo: o quê · tempo: presente · frequência: tempo real
- *Hospital*: "Qual paciente tem maior risco de piora nas próximas 2 horas?" → tipo: quem · tempo: futuro · frequência: tempo real

📌 **ENTREGÁVEL DESTE PASSO:** Para cada Decision Goal, uma ou mais Question Goals, indicando tipo, tempo verbal e frequência.

| Question Goal (a pergunta)                                           | Tipo   | Tempo (passado/presente/futuro) | Frequência |
|----------------------------------------------------------------------|--------|---------------------------------|------------|
| <i>Qual é o sentimento (positivo/negativo) expresso pelo cliente</i> | O quê  | Presente                        | Diária     |
| <i>Quantas avaliações positivas e negativas esse cliente tem?</i>    | Quanto | Passado                         | Diária     |

### 📝 Entregável final da Fase 1

Desenhem (à mão, em slide, ou em ferramenta de diagramação) um diagrama conectando: Ator → Goal → Decision Goal → Question Goal(s), com os indicadores e as anotações informais de qualidade ao lado do Goal.



## CHECKPOINT

Antes de seguir para a Fase 2, mostrem esse diagrama ao professor. Nenhum grupo deve avançar sem ter clareza total sobre o problema de negócio.

## 2 FASE 2 — Analytics Design View

45 minutos · traduzindo a pergunta de negócio em especificação técnica

Objetivo desta fase: traduzir as perguntas de negócio da Fase 1 em especificações técnicas de Machine Learning — e é aqui que formalizamos os Softgoals.

### PASSO 2.1 Tipo de análise

Para cada Question Goal da Fase 1, classifiquem o tipo de análise necessária.

| Tipo        | O que faz                              | Exemplo                                          |
|-------------|----------------------------------------|--------------------------------------------------|
| Preditiva   | Prever um valor futuro ou desconhecido | Prever se o cliente vai cancelar                 |
| Descritiva  | Resumir/explicar o conjunto de dados   | Agrupar clientes em perfis de comportamento      |
| Prescritiva | Recomendar a melhor ação entre opções  | Recomendar qual desconto oferecer a cada cliente |

 **ENTREGÁVEL DESTE PASSO:** Classificação (Preditiva/Descritiva/Prescritiva) para cada Question Goal, com uma frase justificando.

| Question Goal                                                        | Tipo de análise | Justificativa                                                                                                                                                                                                |
|----------------------------------------------------------------------|-----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>Qual é o sentimento (positivo/negativo) expresso pelo cliente</i> | Preditivo       | O modelo recebe um texto não estruturado e prevê a qual rótulo ele pertence.                                                                                                                                 |
| <i>Quantas avaliações positivas e negativas esse cliente tem?</i>    | Descritivo      | O modelo permite que posteriormente seja possível descrever, contabilizar e sumarizar o histórico de dados já existentes armazenados em um banco de dados, consolidando os eventos passados para o operador. |

### PASSO 2.2 Tarefa de ML e algoritmos candidatos

Desçam um nível de abstração: que tarefa técnica de ML corresponde a essa análise, e quais algoritmos poderiam resolvê-la? Listem do mais simples ao mais sofisticado — ainda não é hora de escolher 'o melhor'.

#### Exemplo (streaming — "prever cancelamento")

- Tarefa de ML: Classificação Binária (vai cancelar / não vai cancelar)
- Algoritmos candidatos: regra manual (ex.: 'sem login há 20+ dias'), Regressão Logística, Random Forest, XGBoost, Rede Neural

Se a tarefa parecer grande demais, quebrem em sub-tarefas (ex.: 'cancelamento voluntário' vs. 'cancelamento por falha de pagamento' — causas e dados diferentes).

 **ENTREGÁVEL DESTE PASSO:** Para cada Meta Analítica: a tarefa de ML correspondente e uma lista de 2–4 algoritmos candidatos.

| Meta Analítica                               | Tarefa de ML                                                                | Algoritmos candidatos                                                                                                                                                                                                                                                                                                                                                                   |
|----------------------------------------------|-----------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>Classificação de Sentimento do Review</i> | Classificação Binária de Texto / Análise de Polaridade de Sentimentos (NLP) | <p>Abordagem Léxica de Polaridade: Baseado em regras e dicionário léxico que calcula o score de polaridade a partir de tokens.</p> <p>Regressão Logística: Classificador supervisionado que aprende pesos a partir do texto vetorizado.</p> <p>Random Forest: Classificador baseado em <i>ensembles</i> de árvores de decisão treinados sobre os vetores de frequência de palavras.</p> |
| <i>Histórico de Avaliação do cliente</i>     | Agregação e sumarização de dados                                            | <p>Agregação via pandas: Filtro e contagem em memória das colunas avaliadas por ID do cliente.</p> <p>Consulta relacional: Agregação via instrução SQL.</p>                                                                                                                                                                                                                             |

### PASSO 2.3 Formalizar os Softgoals

Transformem as anotações informais de qualidade da Fase 1 (Passo 1.2) em Softgoals formais — requisitos de qualidade que vão pesar na escolha do algoritmo.

#### Exemplos, com a origem no negócio

- "Não quero muitos alarmes falsos" (fraude) → Softgoal: Baixa taxa de Falso Positivo / Alta Precisão
- "Preciso entender o motivo da recomendação" (saúde) → Softgoal: Explicabilidade
- "A lista precisa estar pronta toda segunda de manhã" (streaming) → Softgoal: Baixa latência / lote compatível com o prazo
- Softgoals técnicos que o time de dados pode trazer, mesmo sem o stakeholder ter pedido: Custo de treino/operação, Privacidade dos dados, Robustez a mudanças de comportamento (drift)

 **ENTREGÁVEL DESTE PASSO:** Lista de 3–5 Softgoals formais, cada um citando de qual anotação da Fase 1 ele se origina (ou indicando que é um softgoal técnico adicional).

| Softgoal                                    | Origem (frase do stakeholder ou 'técnico')           |
|---------------------------------------------|------------------------------------------------------|
| <i>Latência e Priorização em tempo real</i> | Atendente do SAC: "Alerta direto na fila"            |
| <i>Aplicabilidade e Transparência</i>       | Gerente de Vendas: "Precisa ser fácil de entender"   |
| <i>Alta sensibilidade a Críticas</i>        | Gerente de CRM: "Precisamos tratar as insatisfações" |

### PASSO 2.4 Vincular Softgoals a métricas de ML tangíveis

#### O "pulo do gato" do GR4ML

Todo Softgoal precisa virar uma métrica técnica mensurável, ou ele fica bonito no papel e não influencia nada na prática. Alunos de computação tendem a otimizar só a Acurácia — mas se o negócio exige Explicabilidade, um modelo caixa-preta sem SHAP/LIME viola um requisito de negócio, mesmo acertando mais.

#### 💡 Exemplos de vínculo Softgoal → Métrica

- *Fraude*: "Evitar perturbar clientes inocentes" → alta Precisão / baixa taxa de Falso Positivo
- *Saúde*: "Explicabilidade" → uso obrigatório de SHAP/LIME, ou restrição a modelos interpretáveis
- *Streaming*: "Compatível com o prazo semanal" → tempo de inferência em lote < 2h para toda a base

🔗 **ENTREGÁVEL DESTE PASSO:** Uma tabela cruzando Algoritmos (Passo 2.2) × Softgoals (Passo 2.3), com a métrica usada em cada cruzamento, e uma conclusão de qual algoritmo o grupo escolheria.

| Algoritmo                  | Softgoal 1 Latência e Priorização em Tempo Real                                 | Softgoal 2 Explicabilidade e Transparência                                           | Softgoal 3 Alta Sensibilidade a Críticas                                                   |
|----------------------------|---------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|
| <i>Regressão Logística</i> | Excelente (< 10ms por requisição). <i>Métrica</i> : Latência de Inferência (ms) | Alta. <i>Métrica</i> : Pesos/Coefficientes globais do vocabulário                    | Moderada/Alta. <i>Métrica</i> : Recall da Classe Negativa >= 85% e Macro-F1                |
| <i>Bert</i>                | Excelente (<15ms por requisição) <i>Métrica</i> : Latência de Inferência (ms)   | <i>Média Métrica</i> : Feature Importance / MDI ( <i>Mean Decrease in Impurity</i> ) | Alta <i>Métrica</i> : Recall da Classe Negativa >= 85% e Out-of-Bag (OOB) Score / Macro-F1 |
| <i>Random Forest</i>       | Moderada (<60ms por requisição) <i>Métrica</i> : Latência de Inferência (ms)    | baixa <i>Métrica</i> : Requer SHAP / Captum para atribuição de atenção               | Alta <i>Métrica</i> : Recall da Classe Negativa >=85 e Macro-F1                            |

*Conclusão do grupo — qual algoritmo escolheriam e por quê:*

O grupo escolheu a regressão logística pois está alinhada com o menor tempo de inferência desejado pelo SAC, garantindo um alerta rápido, apresenta escalabilidade e transparência total, permitindo identificar quais palavras negativas puxaram a nota do produto para baixo e atende as viabilidades do negócio permitindo que sejam feitos ajustes sem a necessidade de mudanças grandes no projeto e na infraestrutura.

### PASSO 2.5 Conectar de volta ao indicador de negócio

Fechem o ciclo com a Fase 1: expliquem como a melhoria esperada no modelo se traduz em melhoria no indicador de negócio.

#### 💡 Exemplo (streaming)

- "Se o modelo identificar corretamente 80% dos clientes que vão cancelar, e a campanha de retenção converter 30% deles, esperamos reduzir o churn mensal de 5% para ~4,2%."

🔗 **ENTREGÁVEL DESTE PASSO:** Um parágrafo curto conectando o desempenho esperado do modelo ao Indicador definido no Passo 1.2.

Se o modelo identificar corretamente 85% dos reviews negativos em tempo e o SAC converter 10% desses atendimentos críticos, esperamos elevar a taxa de retenção do CRM de 15% para 35% e a média de avaliação dos produtos de 3,9 para 4,3 estrelas.

### 3 FASE 3 — Data Preparation View

45 minutos · conectando os algoritmos às fontes de dados reais

Objetivo desta fase: conectar os algoritmos escolhidos às fontes de dados reais necessárias para treiná-los e alimentá-los.

#### PASSO 3.1 Fontes de dados (entidades e atributos)

Identifiquem as entidades e atributos do mundo real necessários para o modelo — mesmo que hipotéticos.

##### Exemplo (streaming)

- *Cadastro do Cliente: nome, idade, cidade, data de assinatura*
- *Histórico de Visualização: o que assistiu, quando, por quanto tempo*
- *Atendimentos ao Suporte: data, motivo, se foi resolvido*
- *Logs de Pagamento: forma de pagamento, se houve falha de cobrança*

 **ENTREGÁVEL DESTE PASSO:** Lista das tabelas/fontes de dados brutos, com 3–5 campos principais de cada uma.

| Fonte de dados (tabela)           | Principais campos/atributos |
|-----------------------------------|-----------------------------|
| <i>amazon_reviews_dataset.csv</i> | TEXT_COLUMN                 |
| <i>amazon_reviews_dataset.csv</i> | RATING_COLUMN               |
| <i>amazon_reviews_dataset.csv</i> | REVIEWS.USERNAME            |

#### PASSO 3.2 Data Operations — transformações

Descrevam as transformações necessárias para os dados brutos virarem features (colunas prontas para o modelo).

##### Tipos de tratamento, com exemplos

- *Tratamento de nulos: preencher ou descartar registros incompletos*
- *Normalização: colocar variáveis em escalas comparáveis*
- *One-Hot Encoding: transformar categorias (ex.: forma de pagamento) em colunas binárias*
- *Agregações temporais: calcular 'horas assistidas por semana' a partir de logs brutos*
- *Integração: juntar tabelas usando o ID do cliente como chave*

 **ENTREGÁVEL DESTE PASSO:** Lista numerada das transformações aplicadas, na ordem em que ocorrem, do dado bruto até a tabela final.

| Nº | Transformação aplicada                                                                                         | Tabela(s) de origem               |
|----|----------------------------------------------------------------------------------------------------------------|-----------------------------------|
| 1. | Seleção das colunas relevantes<br>(RATING_COLUMN, TEXT_COLUMN)                                                 | <i>amazon_reviews_dataset.csv</i> |
| 2. | Tratamento de nulos: Remoção dos registros com dados NaN com dropna                                            | <i>amazon_reviews_dataset.csv</i> |
| 3  | Categorização: Transformar as notas em sentimentos<br>(>=4 como positivo, 3 como neutro, demais como negativo) | <i>amazon_reviews_dataset.csv</i> |
| 4  | Tokenização das strings: Preparação dos dados para trabalhar com cálculo de polaridade via TextBlob            | <i>amazon_reviews_dataset.csv</i> |

### PASSO 3.3 Dataset final e Pipeline


Mostrem a 'tabela final' que o modelo realmente usa — uma linha por unidade de análise, uma coluna por feature — e conectem-na diretamente às tarefas de ML da Fase 2.

#### 💡 Exemplo de dataset preparado (streaming)

• Colunas: *Cliente\_ID* | *Dias sem logar* | *Horas assistidas/semana* | *Nº reclamações (3 meses)* | *Já teve falha de pagamento?* | *Cancelou (rótulo)*

🔗 **ENTREGÁVEL DESTE PASSO:** Exemplo de tabela final (pode ser fictício, poucas linhas) + um diagrama simples de pipeline: Fontes brutas → Transformações → Dataset Final → Algoritmo.

| Coluna (feature)   | Descrição                                                                  | De qual fonte / transformação vem |
|--------------------|----------------------------------------------------------------------------|-----------------------------------|
| <i>Model</i>       | Dados do objeto python de treinamento                                      | <i>amazon_reviews_dataset.csv</i> |
| <i>predictions</i> | Vetor com os valores previstos (0 ou 1) para a base de teste.              | <i>amazon_reviews_dataset.csv</i> |
| <i>y_test</i>      | Vetor com os valores reais (0 ou 1) para comparação.                       | <i>amazon_reviews_dataset.csv</i> |
| <i>Metrics</i>     | Dicionário com os indicadores consolidados calculados                      | <i>amazon_reviews_dataset.csv</i> |
| <i>Vocab</i>       | Vocabulário de palavras/tokens extraído pelo vetorizador durante o treino. | <i>amazon_reviews_dataset.csv</i> |



 **CHECKPOINT**

Um colega de fora do grupo, lendo o pipeline, deveria entender de onde vem cada coluna da tabela final.

## Ferramentas recomendadas

---

Como o GR4ML estende conceitos do i\* (iStar), os alunos podem utilizar:

- **Ferramentas de diagramação geral:** Miro, Lucidchart ou Draw.io, criando uma legenda própria para os elementos do GR4ML:
  - Retângulos arredondados → Goals (Strategic Goal, Decision Goal, Question Goal)
  - Nuvens → Softgoals
  - Hexágonos → Tasks/Algoritmos
- **Ferramentas acadêmicas baseadas em i\*:** para quem preferir mais formalismo, a piStar tool, adaptada com estereótipos do GR4ML, ajuda na modelagem orientada a objetivos.

## Verificação final

---

Antes de entregar, completem esta frase única, sem inventar nada que não esteja documentado nas fases anteriores. Se alguma parte não existir no material do grupo, é sinal de que uma fase ficou incompleta — voltem e revisem.

### Frase de verificação

"Para ajudar [Ator] a decidir [Decision Goal], respondendo à pergunta [Question Goal], vamos usar [Algoritmo], que satisfaz os softgoals [Softgoals] medidos por [Métricas], usando os dados [Dataset Preparado] vindos de [Fontes de Dados]. Isso deve impactar o indicador [Indicador] em [magnitude esperada]."

### Preenchem a frase com o projeto de vocês

Para ajudar os Gerentes de Vendas, de CRM e operadores de SAC a decidir Qual é o sentimento (positivo/negativo) expresso pelo cliente e quantas avaliações positivas cada cliente tem, vamos usar o algoritmo de Abordagem Léxica de polaridade, que satisfaz os softgoals Latência e Priorização em tempo real, explicabilidade e transparência e Alta Sensibilidade a Críticas medidos pela latência da inferência, pesos e/ou coeficientes globais do vocabulário, recall da classe negativa maior que 85% e pelo Macro-F1. Usando os dados do dataset com as colunas model, predictions, y\_test, métricas e vocab vindas do CSV de treinamento com dados da amazon. Isso deve impactar os indicadores de retenção de clientes que tiveram experiências negativas para 35%, manter a taxa de avaliação positiva dos produtos acima de 85% no e-commerce e Diminuir o SLA de resposta para menos de 1 dia útil e aumentar a conversão de notas negativas para neutras ou positivas em 10%



## FASE 4 — Dos Modelos aos Requisitos

30 minutos · transformando os diagramas GR4ML em uma lista de requisitos formal

Até aqui, o grupo construiu três diagramas/modelos. Mas um diagrama, sozinho, ainda não é um documento de requisitos — é preciso 'traduzir' cada elemento do modelo em frases claras, testáveis, que um time de engenharia consiga implementar e verificar. Essa tradução segue sempre o mesmo caminho: cada elemento do GR4ML já modelado nas fases anteriores dá origem a um tipo específico de requisito.



### Por que isso importa

Um Decision Goal ou um Softgoal, por si só, é uma intenção — não uma instrução que um desenvolvedor consiga implementar ou testar. A elicitação só termina de fato quando a intenção vira um requisito redigido de forma objetiva, rastreável até o elemento do modelo que o originou.

## Mapa de tradução: do elemento do GR4ML ao tipo de requisito

| Elemento já modelado                                    | Tipo de requisito gerado                        | Pergunta-guia para redigir                                                      |
|---------------------------------------------------------|-------------------------------------------------|---------------------------------------------------------------------------------|
| Decision Goal + Question Goal + Insight (Fase 1)        | Requisito Funcional (RF)                        | O que exatamente o sistema precisa calcular ou entregar?                        |
| Softgoal + Métrica associada (Passo 2.3–2.4)            | Requisito Não-Funcional (RNF)                   | Que qualidade o sistema deve garantir, e como ela será medida?                  |
| Entidades + Dataset Preparado + Transformações (Fase 3) | Requisito de Dados (RD)                         | Que dados precisam ser coletados, integrados e tratados, e de onde vêm?         |
| Indicador (Passo 1.2)                                   | Critério de Aceitação do conjunto de requisitos | Como saberemos, no negócio, que os requisitos implementados geraram valor real? |

### PASSO 4.1 Redigir os Requisitos Funcionais (RF)

Um Requisito Funcional descreve uma capacidade que o sistema deve ter. Ele nasce da junção entre a decisão (Decision Goal), a pergunta que a apoia (Question Goal) e o insight que a responde (Fase 1).



#### Modelo de frase (template)

- "O sistema deve [ação/cálculo], a partir de [dados de entrada], para permitir que [Ator] [decisão apoiada]."



#### Exemplo preenchido (streaming)

- "O sistema deve calcular uma pontuação de risco de cancelamento (0 a 100) para cada cliente ativo, a partir do histórico de uso, suporte e pagamento dos últimos 12 meses, atualizada semanalmente, para permitir que o Gerente de Retenção decida quais clientes recebem desconto."



**ENTREGÁVEL DESTE PASSO:** Um Requisito Funcional (RF) redigido para cada Insight identificado na Fase 1, seguindo o template acima.

| ID  | Requisito Funcional (RF)                    | Origem no modelo (Insight/Decision Goal)                       |
|-----|---------------------------------------------|----------------------------------------------------------------|
| RF1 | <i>Mapeamento e Rotulagem de Sentimento</i> | Qual é o sentimento (positivo/negativo) expresso pelo cliente? |
| RF2 | <i>Classificação Automática de Texto</i>    | Qual é o sentimento (positivo/negativo) expresso pelo cliente? |

| ID  | Requisito Funcional (RF)                  | Origem no modelo (Insight/Decision Goal)                   |
|-----|-------------------------------------------|------------------------------------------------------------|
| RF3 | <i>Agregação do Histórico por Cliente</i> | Quantas avaliações positivas e negativas esse cliente tem? |

#### PASSO 4.2 Redigir os Requisitos Não-Funcionais (RNF)

Um Requisito Não-Funcional descreve uma qualidade que o sistema deve garantir — nasce diretamente dos Softgoals formalizados e das métricas que vocês vincularam a eles no Passo 2.4.



##### Modelo de frase (template)

- "O sistema deve garantir [qualidade/softgoal], medida por [métrica], com [meta/limite]."



##### Exemplos preenchidos

- "O sistema deve fornecer explicabilidade para cada predição de risco, medida pela disponibilidade de valores SHAP por cliente." (origem: Softgoal Explicabilidade)
- "O sistema deve processar toda a base de clientes em lote em menos de 2 horas." (origem: Softgoal Baixa latência / prazo semanal)



**ENTREGÁVEL DESTE PASSO:** Um Requisito Não-Funcional (RNF) redigido para cada Softgoal formalizado no Passo 2.3, usando a métrica definida no Passo 2.4.

| ID   | Requisito Não-Funcional (RNF)               | Origem no modelo (Softgoal/Métrica)  |
|------|---------------------------------------------|--------------------------------------|
| RNF1 | <i>Tempo de Inferência</i>                  | Latência e Priorização em Tempo Real |
| RNF2 | <i>Auditabilidade dos Coeficientes</i>      | Explicabilidade e Transparência      |
| RNF3 | <i>Recall Mínimo para Reviews Negativos</i> | Alta Sensibilidade a Críticas        |

#### PASSO 4.3 Redigir os Requisitos de Dados (RD)

Um Requisito de Dados descreve o que precisa ser coletado, integrado ou tratado — nasce das Entidades, do Dataset Preparado e das transformações mapeadas na Fase 3.



##### Modelo de frase (template)

- "O sistema deve integrar/coletar/tratar [dado], proveniente de [fonte], aplicando [transformação], para alimentar [RF correspondente]."



##### Exemplo preenchido (streaming)

- "O sistema deve integrar dados de Cadastro do Cliente, Histórico de Visualização, Atendimentos ao Suporte e Pagamentos, tratando valores nulos e agregando o histórico de visualização em 'horas assistidas por semana', para alimentar o requisito RF-01."



**ENTREGÁVEL DESTE PASSO:** Um ou mais Requisitos de Dados (RD), cobrindo as fontes e transformações da Fase 3, cada um referenciando o RF que ele alimenta.

| ID  | Requisito de Dados (RD)               | RF que este dado alimenta            |
|-----|---------------------------------------|--------------------------------------|
| RD1 | <i>Atributo de Texto da Avaliação</i> | Classificação Automática de Texto    |
| RD2 | <i>Atributo de Rating/Nota</i>        | Mapeamento e Rotulagem de Sentimento |
| RD3 | <i>Identificador Único do Cliente</i> | Agregação do Histórico por Cliente   |

#### PASSO 4.4 Definir o Critério de Aceitação (fechando o ciclo com o negócio)

Por fim, reconectem tudo ao Indicador de negócio definido lá no Passo 1.2 — é isso que prova que os requisitos, uma vez implementados, geram valor real, e não apenas um modelo tecnicamente correto.

##### Modelo de frase (template)

• "Este conjunto de requisitos será considerado bem-sucedido se [indicador] atingir [meta], observado em [período/frequência]."

##### Exemplo preenchido (streaming)

• "Este conjunto de requisitos será considerado bem-sucedido se a taxa mensal de churn cair de 5% para 4,25% em até 6 meses após o lançamento."

 **ENTREGÁVEL DESTE PASSO:** Uma frase de critério de aceitação, conectando os RF/RNF/RD ao Indicador de negócio da Fase 1.

Este conjunto de requisitos será considerado bem-sucedido se o tempo médio de primeira resposta no SAC para clientes insatisfeitos cair de 24 horas para menos de 2 horas e a taxa de retenção/resolução de clientes em risco aumentar em 15%, observado no período de 3 meses após o lançamento do modelo em produção.

##### Como reconhecer um requisito bem escrito

Use sempre 'o sistema deve...' (nunca 'seria bom se' ou 'o ideal seria'). Um requisito por frase — não amarrem duas exigências na mesma sentença. Ele precisa ser testável: alguém de fora do grupo deveria conseguir dizer, olhando o sistema pronto, se aquele requisito foi ou não atendido. E ele precisa ser rastreável: sempre cite de qual elemento do modelo GR4ML (Decision Goal, Softgoal, Entidade) aquele requisito se originou — é essa rastreabilidade que prova que a elicitação foi feita de ponta a ponta, e não inventada na hora de escrever o documento.

##### CHECKPOINT

A tarefa só está completa quando existe uma lista numerada de RFs, RNFs e RDs, cada um rastreável a um elemento específico dos modelos das Fases 1 a 3, e um critério de aceitação ligado ao Indicador de negócio.



## Estrutura do documento a ser entregue

---

- 1. Contexto do projeto (Fase 0)
- 2. Diagrama e tabelas da Business View (Fase 1)
- 3. Tabelas de tarefas/algoritmos/softgoals/métricas da Analytics Design View (Fase 2)
- 4. Diagrama de pipeline da Data Preparation View (Fase 3)
- 5. Frase de verificação final preenchida
- 6. Lista consolidada de Requisitos Funcionais, Não-Funcionais e de Dados, com critério de aceitação (Fase 4)
- 7. Reflexão crítica (½ página): o ML era realmente necessário aqui? O que a formalização dos Softgoals e a tradução para requisitos revelaram que não estava claro na conversa inicial com o stakeholder?

### Reflexão crítica do grupo

O preenchimento do GR4ML, com propósito de levantar as necessidades e critérios de trabalho levantados pelos stakeholders, se mostrou de suma importância para a resolução do problema proposto. Conseguimos observar que o ML realmente se fez necessário aqui, dada a velocidade esperada do resultado, a volumetria de dados obtidos por meio dos feedbacks dos usuários e as metas impostas pelas áreas interessadas torna inviável uma validação manual. A formalização dos softgoals permitiu transformar as expectativas informais e vagas das áreas interessadas em requisitos não funcionais (RNF) quantificáveis e devidamente atreladas às métricas do Machine Learning proposto. Formalizamos o desejo de ter um alerta em tempo real por meio do RNF01; Conseguimos transparência através do RNF02, que busca entender e justificar as notas ruins, conseguimos tratar as insatisfações observando a perda mensurada pela métrica introduzida pelo RNF03 e construímos requisitos de dados RD que permitiram amarrar os requisitos funcionais com requisitos não funcionais.

A construção do GR4ML permitiu ao grupo entender que a construção de uma solução de Machine Learning vai muito além da escolha de algoritmos ou do ajuste de parâmetros; trata-se de um exercício contínuo de alinhamento entre a área de desenvolvimento e as áreas que geram valor ao negócio. O Framework permitiu transformar um desafio operacional amplo, a gestão de insatisfação em avaliações de e-commerce, em uma arquitetura de dados rastreável e bem definida.